

Quem sou eu... filha, irmã, tia e aspirante a peregrina

- Graduação em Ciência da Computação pela Universidade Católica de Goiás
- Especialização em Redes de Computadores pela Universidade Salgado de Oliveira
- MBA em Gerenciamento de Projetos pela Fundação Getúlio Vargas
- Mestrado em Ciência da Computação pela Universidade Federal de Goiás
- Doutorado em Ciência da Computação pela Universidade Federal de Goiás
- MBA em Tecnologia para Negócios: AI, Data Science e Big Data pela Pontifícia Universidade Católica do Rio Grande do Sul
- Professora/coordenadora dos cursos de graduação: Ciência da Computação, Engenharia da Computação, Sistemas de Informação, Análise e Desenvolvimento de Sistemas, Data Science, Defesa Cibernética e Gestão de Tecnologia (UNIALFA, ESTÁCIO, UNIP, PUCGOIÁS, IPOG)
- Professora de cursos de pós graduação: Engenharia de Software, Big Data e Machine Learning (UniAnhaguera, Faculdade Sul-Americana)
- Atualmente Analista Judiciária - Ciência de Dados no Tribunal de Justiça do Distrito Federal e Territórios lotada na SUDES

## UNIDADE 1: Inteligência Artificial

- 1.1. Fundamentos do Aprendizado de Máquina
- 1.2. Tipos de Tarefas de Aprendizado
  - 1.2.1. Supervisionado
  - 1.2.2. Não supervisionado
  - 1.2.3. Semi supervisionado
  - 1.2.4. Aprendizado por reforço
- 1.3. Modelagem preditiva



Prática (TOY): Classificação de casos de Alzheimer (dados fictícios)

## UNIDADE 3: Regressão Linear

- 3.1 Previsões simples (Regressão linear)
- 3.2 Previsões complexas (Regressão linear múltipla)
- 3.3 Algoritmos de Classificação
  - 3.3.1 Métodos simbólicos: Árvore de Decisão
  - 3.3.2 Métodos ensemble: Random Forest



Prática: Previsão da carga de trabalho dos juízes (dados fictícios)

## UNIDADE 5: Redes Neurais

- 5.1 Estrutura básica de uma rede neural
- 5.2 Arquitetura de redes neurais
  - 5.2.1 Perceptron
  - 5.2.2 Multilayer Perceptron
- 5.3 Treinamento de redes neurais
  - 5.3.1 Algoritmos de retropropagação
  - 5.3.2 Otimização de pesos
  - 5.3.3 Função de ativação
- 5.4 Arquiteturas de Redes Neurais Profundas



Prática: Predição do tempo de atravessamento dos processos (dados fictícios)

## UNIDADE 2: Tratamento dos dados

- 2.1. Análise exploratória de dados (EDA)
- 2.2. Limpeza de dados
- 2.3. Transformação de dados
  - 2.3.1. Divisão dos dados
  - 2.3.2. Balanceamento
  - 2.3.3. Escalonamento
  - 2.3.4. Codificação e criação de features
- 2.4. Redução de dimensionalidade



Prática: Planejamento de sucessão cargos de liderança (dados fictícios)

## UNIDADE 4: Otimização e desempenho

- 4.1 Otimização de hiperparâmetros e regularização
  - 4.1.1 Técnicas de avaliação de modelos
    - 4.1.1.1 Overfitting e underfitting
    - 4.1.1.2 Interpretabilidade dos modelos
    - 4.1.1.3 Questões éticas e de viés
  - 4.1.2 Validação cruzada
  - 4.1.3 GridSearchCV
  - 4.1.4 Avaliação de métricas



Prática: Previsão da carga de trabalho dos juízes (refinamento)

## UNIDADE 6: Large Language Models

- 6.1 Redes Neurais Generativas (GAN)
- 6.2 Conceitos de Processamento de Linguagem Natural
- 6.3 Principais modelos LLM
  - 6.3.1 Open AI
  - 6.3.2 Llama

Prática: Fine-Tuning do Llama3

## UNIDADE 7: Treinando Modelos LLMs

- 7.1 Retrieval Augmented Generation
- 7.2 Framework LangChain
- 7.3 Llama 3

Prática: Chatbot na base de informações da ouvidoria do TJDF

(dados reais)

# Material e Ambiente

**Ambiente de compartilhamento de códigos**, datasets, slides e referências adicionais usados nas aulas:

- repositório no GitHub (<https://github.com/joelmaf/course.ai>). À medida que as aulas forem avançando esse repositório será atualizado

Para entrega das atividades usar o AVA

- Ambiente de execução

A instalar na sua máquina

Anaconda Navigator

Google Colab

# Agenda

## **UNIDADE 1: Inteligência Artificial**

- Fundamentos do Aprendizado de Máquina
- Tipos de Tarefas de Aprendizado
  - Supervisionado
  - Não supervisionado
  - Semi supervisionado
  - Aprendizado por reforço
- Modelagem preditiva

# Ciência (análise) de Dados (na opinião de especialistas)

- Ciência de dados é um **processo** (Shingau Manjengwa, CEO, Fireside Analytics)
- **Validação de hipóteses e modelos** através de dados (Rafael Silva, Data Scientist)
- **Descobrir insights escondidos** nos dados (Diana Diaz, Data Scientist)
- Tradução de **dados em histórias** (Luis O. Martins, Data Scientist)
- É o **estudo dos dados** (Stephen Sherman, Data Scientist)
- Envolve **ciência e dados** (Murtaza Haider PhD)

Grande quantidade  
de dados



Capacidade  
computacional



Análise e novos  
conhecimentos

# Ciência (análise) de Dados (base)

- Em geral, foco em um **problema específico**  
Clarificar um problema que a empresa que resolver
- Quais **dados precisamos** para resolver o problema?
- Quais as **fontes** (estruturado ou não estruturado) **de dados**?
- Quais **modelos** serão utilizados para explorar (padrões e/ou anomalias)

Storytelling



Visualização



Comunicação

# Habilidades Essenciais

- Curiosidade
  - O que fazer com os dados
- Habilidade de julgamento
  - Por onde começar
- Habilidade de argumentação
  - Aprender com os dados
- Habilidade de contar histórias
  - Storytelling

You learn from data!!!!

# Como Resolver a Situação?

## Classificação de casos de Alzheimer

ID	M/F	Hand	Age	Educ	SES	MMSE	CDR	eTIV	nWBV	ASF	Delay
OAS1_0001_MR1	F	R	74	2.0	3.0	29.0	0.0	1344	0.743	1.306	NaN
OAS1_0002_MR1	F	R	55	4.0	1.0	29.0	0.0	1147	0.810	1.531	NaN
OAS1_0003_MR1	F	R	73	4.0	3.0	27.0	0.5	1454	0.708	1.207	NaN
OAS1_0004_MR1	M	R	28	NaN	NaN	NaN	NaN	1588	0.803	1.105	NaN
OAS1_0005_MR1	M	R	18	NaN	NaN	NaN	NaN	1737	0.848	1.010	NaN

A escala clínica usada para avaliar o estágio de gravidade da demência em pacientes: **demência muito leve**, **demência leve**, **demência moderada**, **além de sem demência**

['CDR'] == 0.0 = "SD"  
['CDR'] == 0.5 = "DML"  
['CDR'] == 1.0 = "DL"  
['CDR'] == 2.0 = "DM"

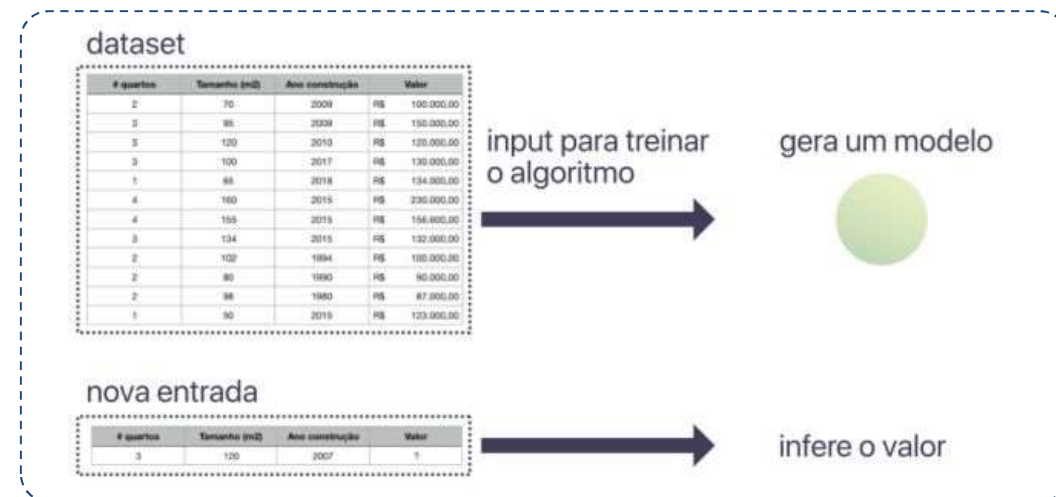
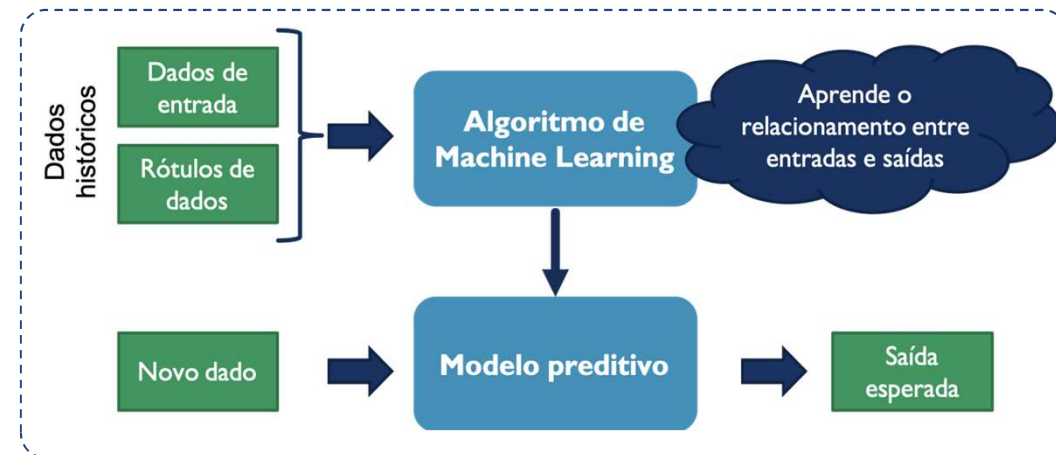


- ☐ **ID** (identificação)
- ☐ **Sexo** (M/F)
- ☐ **Mão dominante** (Hand)
- ☐ **Idade** (Age)
- ☐ **Nível de educação** (Edu)
- ☐ **Status socioeconômico** (SES)
- ☐ **Pontuação** no Mini-Mental State Examination (MMSE) que avalia a função cognitiva
- ☐ **Classificação do Clinical Dementia Rating (CDR)** que indica o estágio de gravidade da demência
- ☐ **Volume total do cérebro e do crânio** (eTIV)
- ☐ **Volume Cerebral Total Normalizado** (nWBV) que mede o volume cerebral relativo ao tamanho total do cérebro
- ☐ Valor único do **tamanho relativo do cérebro** em relação a um atlas padrão (ASF)
- ☐ **Atraso (Delay)**, medido em meses, entre a aquisição das imagens cerebrais e a avaliação clínica ou cognitiva dos participantes




# Aprendizado de Máquina

- Compreensão dos padrões presentes em um conjunto de dados.
- Algoritmos são alimentados com grandes quantidades de dados.
- Técnicas de ML são capazes de:
  - treinar sua inteligência por meio de dados de entrada
  - criar modelos que conseguem tomar decisões baseadas nos resultados obtidos por meio do treinamento.



# Supervisionado e Não Supervisionado

Os dados **contêm a resposta desejada (rotulados)**




O algoritmo não será supervisionado, **não há uma resposta prévia.**

# Aprendizado Supervisionado

DADOS DE ENTRADA (TREINO DO MODELO)

Profissão	Salário	Tipo de Dívida	Rótulo (Pagou?)
Médico	15000	Consignado	Sim
Estudante	1000	Empréstimo X	Não
Apostentado	1200	Consignado	Sim
Economista	5000	Empréstimo X	Sim

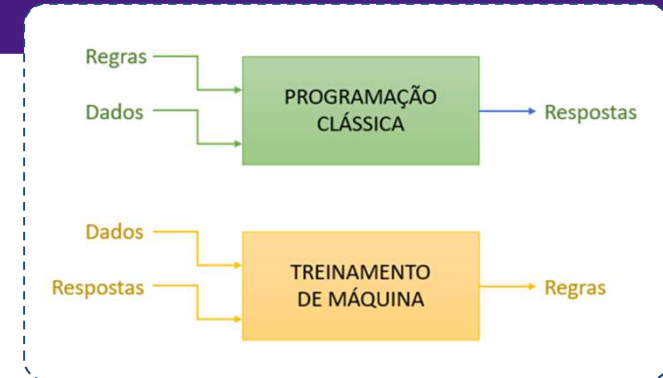


PREDIÇÃO


Profissão	Salário	Tipo de Dívida	Irá Pagar?
Médico	15000	Consignado	Sim
Estudante	1000	Empréstimo X	Não

NOVOS DADOS

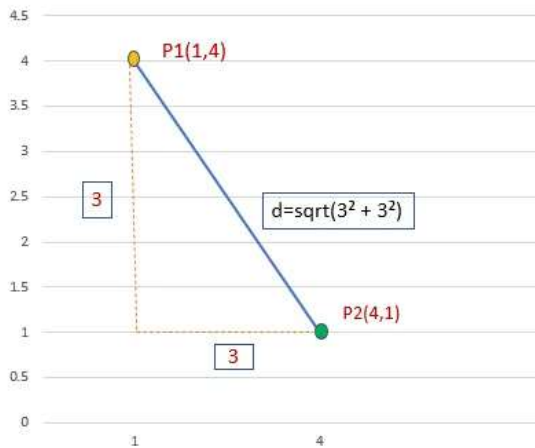

Profissão	Salário	Tipo de Dívida
Médico	15000	Consignado
Estudante	1000	Empréstimo X





# Aprendizado Supervisionado



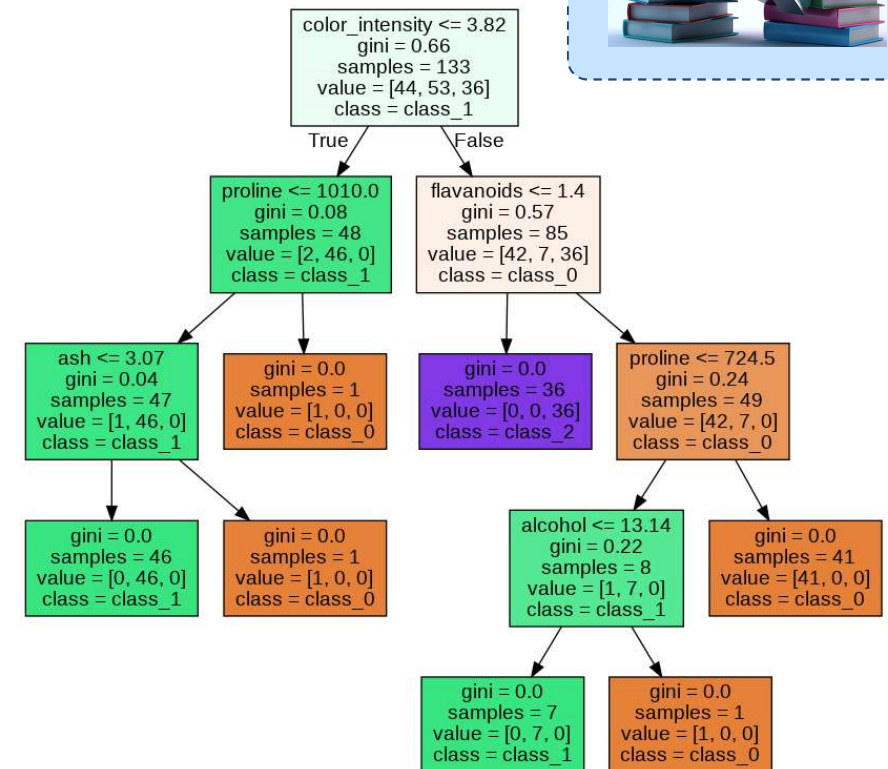
## KNN



## SVM



## Árvore de Decisão





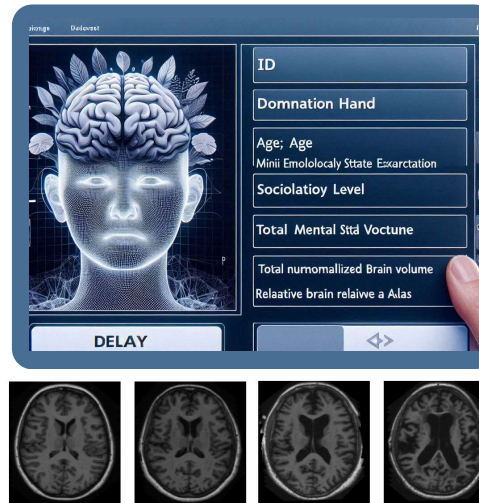
# E agora...como Resolver a Situação?

## Classificação de casos de Alzheimer

ID	M/F	Hand	Age	Educ	SES	MMSE	CDR	eTIV	nWBV	ASF	Delay
OAS1_0001_MR1	F	R	74	2.0	3.0	29.0	0.0	1344	0.743	1.306	NaN
OAS1_0002_MR1	F	R	55	4.0	1.0	29.0	0.0	1147	0.810	1.531	NaN
OAS1_0003_MR1	F	R	73	4.0	3.0	27.0	0.5	1454	0.708	1.207	NaN
OAS1_0004_MR1	M	R	28	NaN	NaN	NaN	NaN	1588	0.803	1.105	NaN
OAS1_0005_MR1	M	R	18	NaN	NaN	NaN	NaN	1737	0.848	1.010	NaN

A escala clínica usada para avaliar o estágio de gravidade da demência em pacientes: **demência muito leve**, **demência leve**, **demência moderada**, **além de sem demência**

['CDR'] == 0.0 = "SD"  
['CDR'] == 0.5 = "DML"  
['CDR'] == 1.0 = "DL"  
['CDR'] == 2.0 = "DM"



- ☐ **ID** (identificação)
- ☐ **Sexo** (M/F)
- ☐ **Mão dominante** (Hand)
- ☐ **Idade** (Age)
- ☐ **Nível de educação** (Edu)
- ☐ **Status socioeconômico** (SES)
- ☐ **Pontuação** no Mini-Mental State Examination (MMSE) que avalia a função cognitiva
- ☐ **Classificação do Clinical Dementia Rating (CDR)** que indica o estágio de gravidade da demência
- ☐ **Volume total do cérebro e do crânio** (eTIV)
- ☐ **Volume Cerebral Total Normalizado** (nWBV) que mede o volume cerebral relativo ao tamanho total do cérebro
- ☐ Valor único do **tamanho relativo do cérebro** em relação a um atlas padrão (ASF)
- ☐ **Atraso (Delay)**, medido em meses, entre a aquisição das imagens cerebrais e a avaliação clínica ou cognitiva dos participantes



Ciência de dados é um **processo**

Shingau Manjengwa, CEO, Fireside Analytics

É o estudo **dos** dados

Stephen Sherman, Data Scientist

# Passo 1: Limpeza e Transformação

1. Delay, ID e Hand: **colunas descartadas** (dados faltosos sem valor estatístico), só tem destros.

2. **Removidas as linhas** que apresentem:

- Dado faltante
- Demência mais avançada 2.0, só tem dois casos (descartado)


1. M/F" transformada em quantitativa utilizando o método de codificação **One Hot-Encoder**

2. **Padronização** dos dados

	Age	Educ	SES	MMSE	CDR	eTIV	nWBV	ASF	M/F_F	M/F_M	CDR_
0	74	2.0	3.0	29.0	0.0	1344	0.743	1.306	1.0	0.0	SD
1	55	4.0	1.0	29.0	0.0	1147	0.810	1.531	1.0	0.0	SD
2	73	4.0	3.0	27.0	0.5	1454	0.708	1.207	1.0	0.0	DML
3	74	5.0	2.0	30.0	0.0	1636	0.689	1.073	0.0	1.0	SD
4	52	3.0	2.0	30.0	0.0	1321	0.827	1.329	1.0	0.0	SD

- Encoding de variáveis categóricas
- Normalização e padronização
- Engenharia de características polinomiais
- Transformações logarítmicas
- Discretização (binning)
- Feature scaling
- Manipulação de outliers
- Tratamento de valores ausentes (imputação)
- Seleção features
- Feature splitting
- Feature creating

# Passo 2: Correlação



Estudo sobre a correlação (correlação de Pearson) entre as variáveis remanescentes e a variável alvo "CDR"

MMSE	-0.739747
nWBV	-0.495352
Age	0.310039
Educ	-0.217249
SES	0.178845
ASF	-0.134869
eTIV	0.127219
M/F_F	-0.081782
M/F_M	0.081782

```
dataset[['MMSE', 'nWBV', 'Age', 'CDR']]
```





Descobrir insights escondidos nos dados

Diana Diaz, Data Scientist

Validação de hipóteses e modelos através  
de dados

Rafael Silva, Data Scientist

# Passo 3: Hiperparâmetros

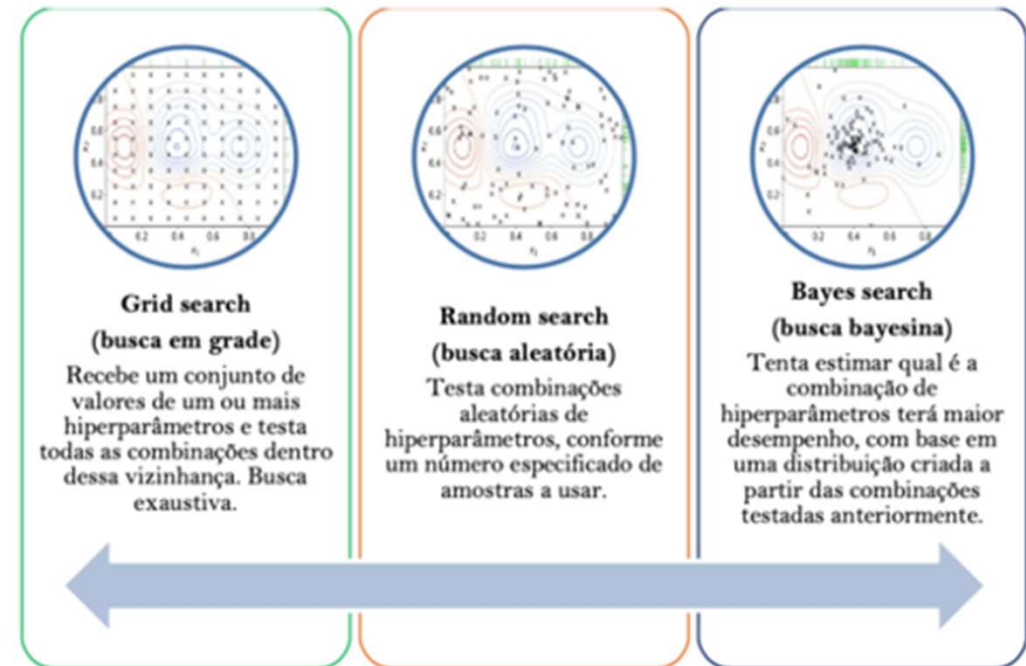


## Métodos automatizados de busca de hiperparâmetros

```
modelo = KNeighborsClassifier(n_neighbors = 3)
modelo.fit(X_train, y_train)
```

```
from sklearn.model_selection import GridSearchCV
param = {
    'n_neighbors': list(range(1, 41, 2)),
    'weights': ['uniform', 'distance'],
    'metric': ['euclidean', 'minkowski', 'manhattan'],
    'p': [1, 2]
}
knn = KNeighborsClassifier()
grid_search = GridSearchCV(knn, param, cv=3) # validação com 3 dobras
grid_search.fit(train.drop('CDR_', axis=1), train['CDR_'])
print("Melhores hiperparâmetros:")
print(grid_search.best_params_)
```

```
sklearn.neighbors.KNeighborsClassifier(n_neighbors=5, *,
weights='uniform', algorithm='auto', leaf_size=30, p=2,
metric='minkowski', metric_params=None, n_jobs=None)
```



# Passo 4: Avaliação

Relatório de Classificação:

	precision	recall	f1-score	support
SD	0.93	0.93	0.93	15
DML	0.75	0.60	0.67	5
DL	0.67	1.00	0.80	2
accuracy			0.86	22
macro avg	0.78	0.84	0.80	22
weighted avg	0.87	0.86	0.86	22

Verificação da qualidade do modelo

$$\text{Acurácia} = \frac{\checkmark \text{👍 TP} + \checkmark \text{👎 TN}}{\checkmark \text{👍 TP} + \checkmark \text{👎 TN} + \text{✗} \text{👍 FP} + \text{✗} \text{👎 FN}}$$

$$\text{Precisão} = \frac{\checkmark \text{👍 TP}}{\checkmark \text{👍 TP} + \text{✗} \text{👍 FP}}$$

$$\text{Revocação} = \frac{\checkmark \text{👍 TP}}{\checkmark \text{👍 TP} + \text{✗} \text{👎 FN}}$$

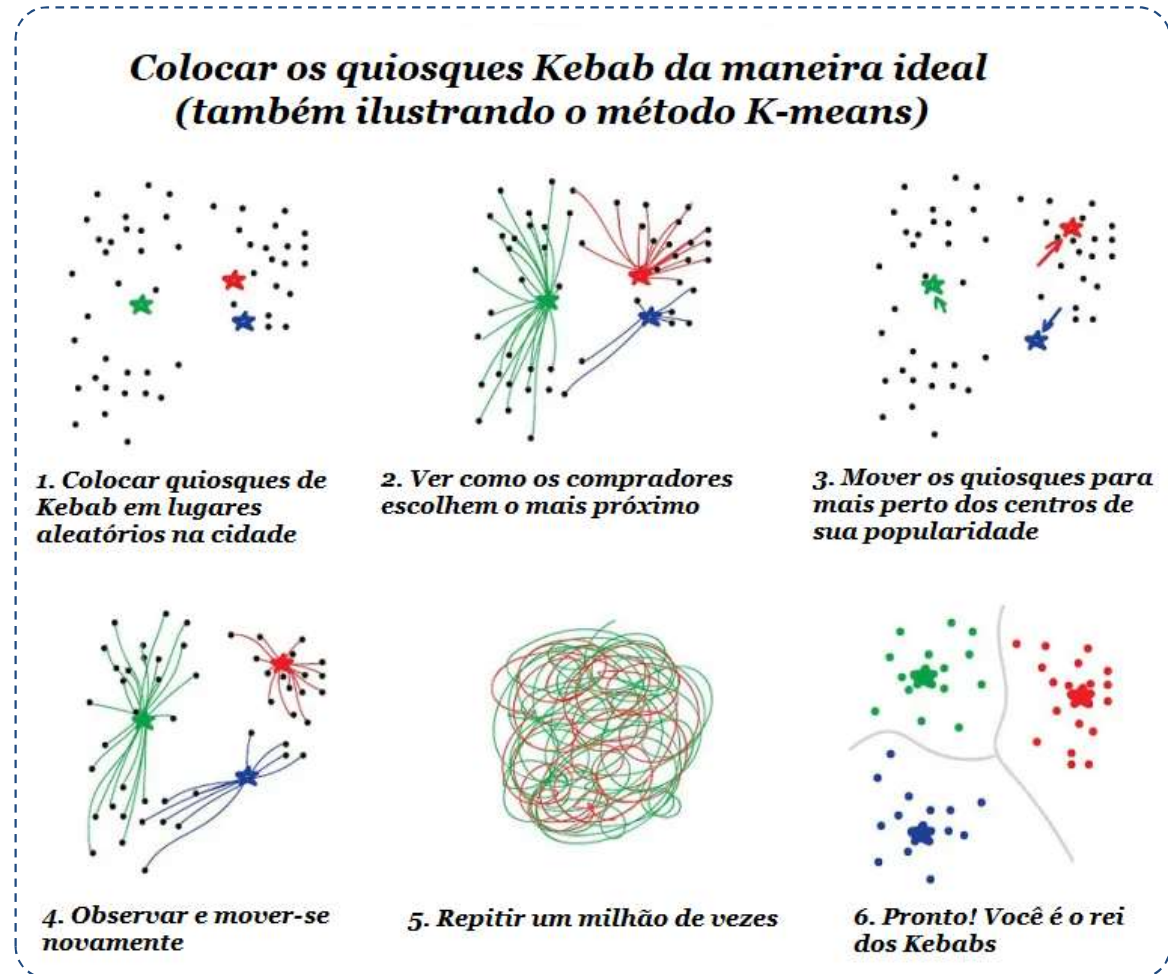
$$F_1 = 2 * \frac{\text{precisão} * \text{recall}}{\text{precisão} + \text{recall}}$$

		P R E D I T O	
		👍 POSITIVO	👎 NEGATIVO
R E A L	👍 POSITIVO	TP verdadeiro positivo	FN falso negativo
	👎 NEGATIVO	FP falso positivo	TN verdadeiro negativo

	Previsão	Esperado
28	SD	SD
206	SD	SD
189	SD	DML
37	SD	SD
169	SD	SD
38	DL	DL
151	DML	SD

# Aprendizado não Supervisionado

- **Não existem resultados pré-definidos** para o modelo utilizar como referência para aprender
- **Exemplos de uso:**
  - Segmentação de mercado (tipos de clientes, fidelidade);
  - Mesclar pontos próximos em um mapa;
  - Compressão de imagem;
  - Analisar e rotular novos dados;
  - Detectar um comportamento anormal.






# Aprendizado por Reforço

## Agente

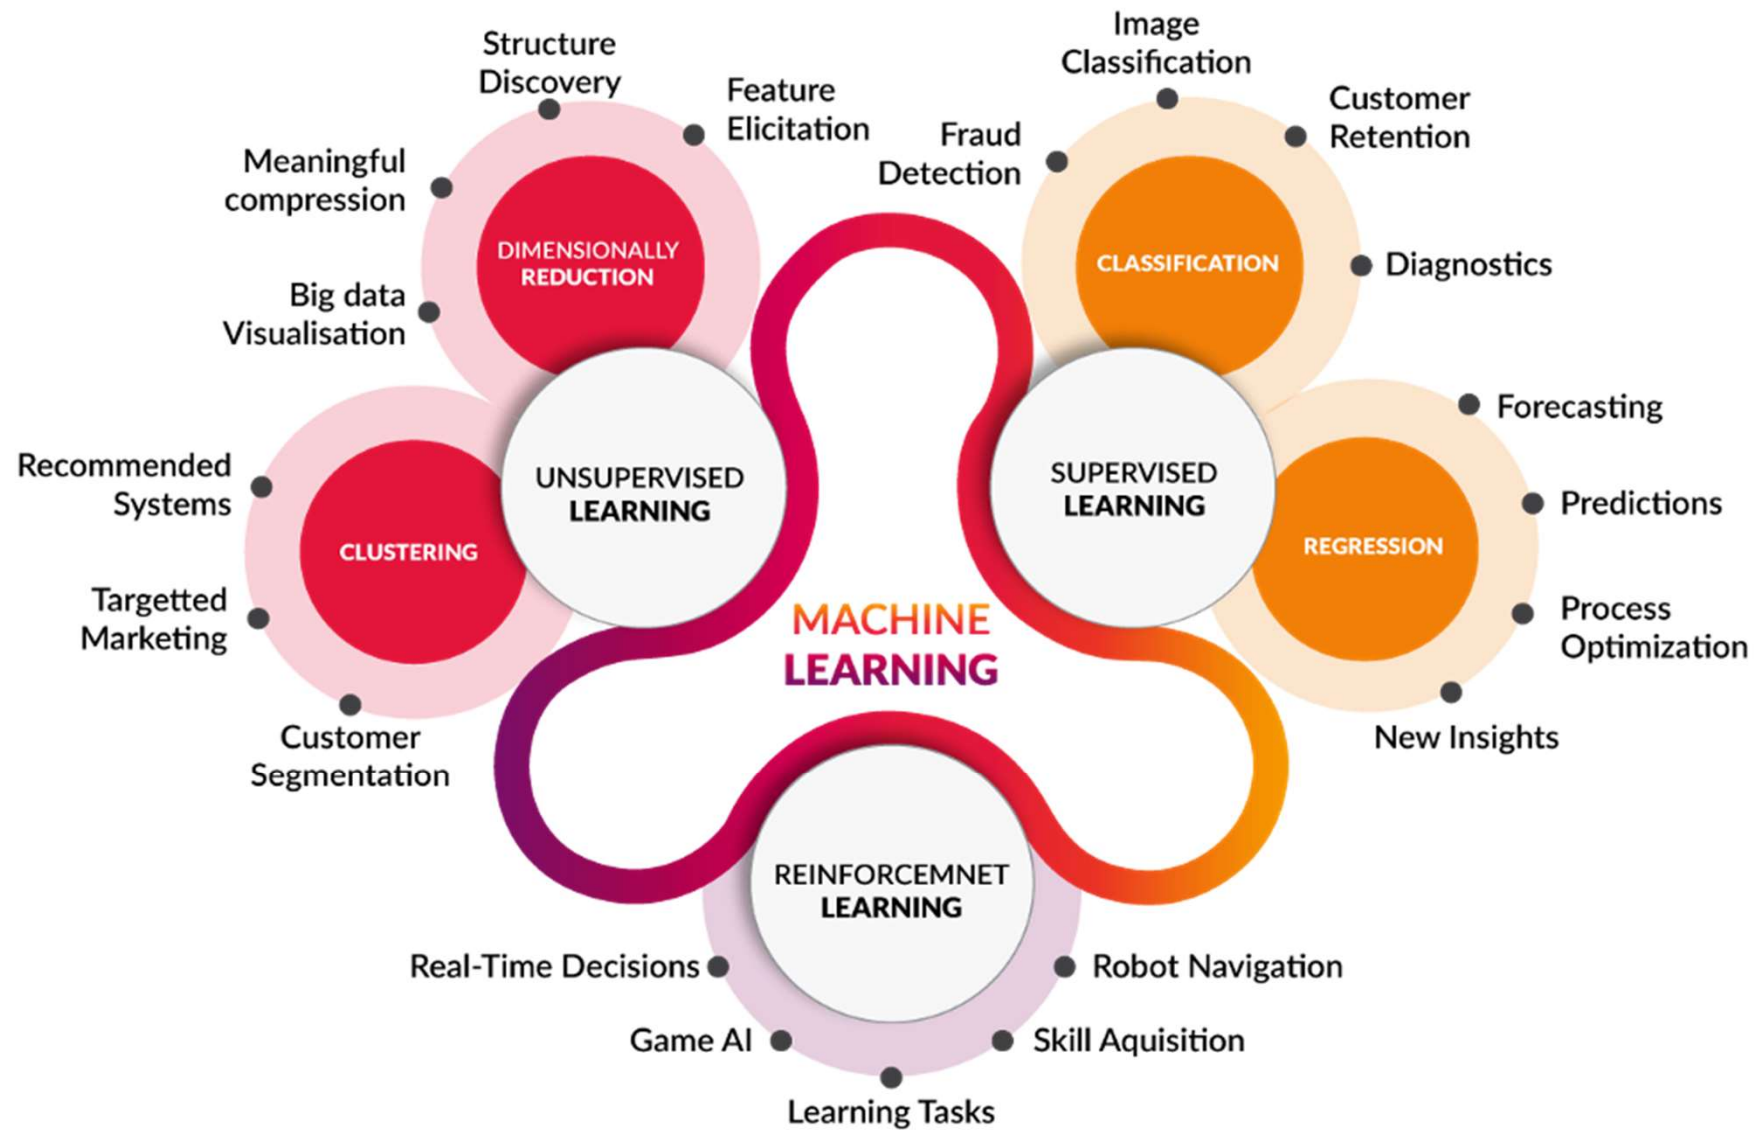
## Tentativa e erro

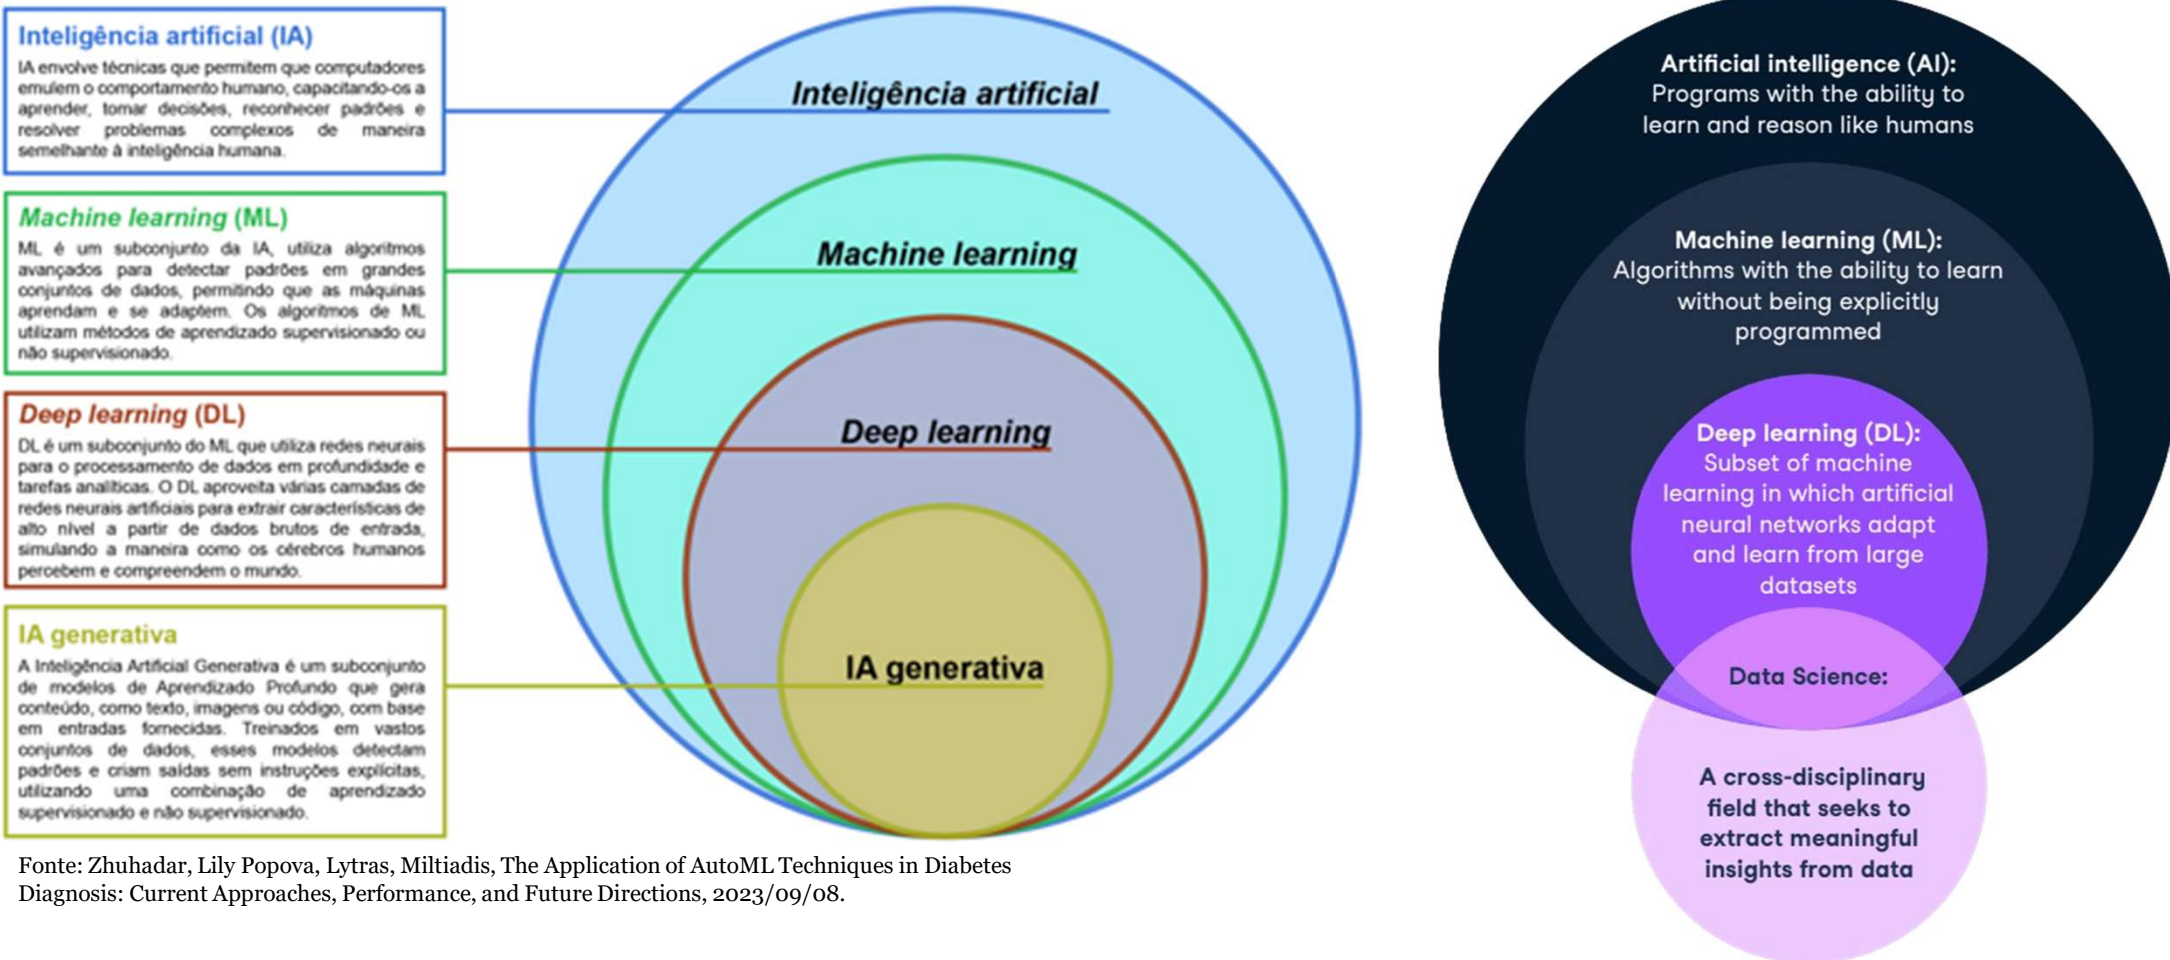
## Recompensa ou punição



- **Jogos manipuladores** : jogos complexos como xadrez, Go e videogames. AlphaGo, desenvolvido pela DeepMind, é um exemplo famoso de agente RL que derrotou jogadores Go de classe mundial.
- **Robótica**: tarefas como braço robótico ao controle, navegação e direção autônoma.
- **Sistemas de Recomendação**: Empresas como Netflix use RL para melhorar seus algoritmos de recomendação. O sistema aprende com as interações e feedback dos usuários para sugerir conteúdo personalizado.
- **Assistência médica**: A RL é aplicada para otimizar planos de tratamento, dosagens de medicamentos e alocação de recursos médicos. Pode ajudar a personalizar as intervenções médicas para os pacientes.







Fonte: Zhuhadar, Lily Popova, Lytras, Miltiadis, The Application of AutoML Techniques in Diabetes Diagnosis: Current Approaches, Performance, and Future Directions, 2023/09/08.



Analytics And Data Science

## Data Scientist: The Sexiest Job of the 21st Century

Meet the people who can coax treasure out of messy, unstructured data. by Thomas H. Davenport and DJ Patil

From the Magazine (October 2012)

(October 2012)




<https://hbr.org/2012/10/data-scientist-the-sexiest-job-of-the-21st-century>

Analytics And Data Science


## Is Data Scientist Still the Sexiest Job of the 21st Century?

by Thomas H. Davenport and DJ Patil

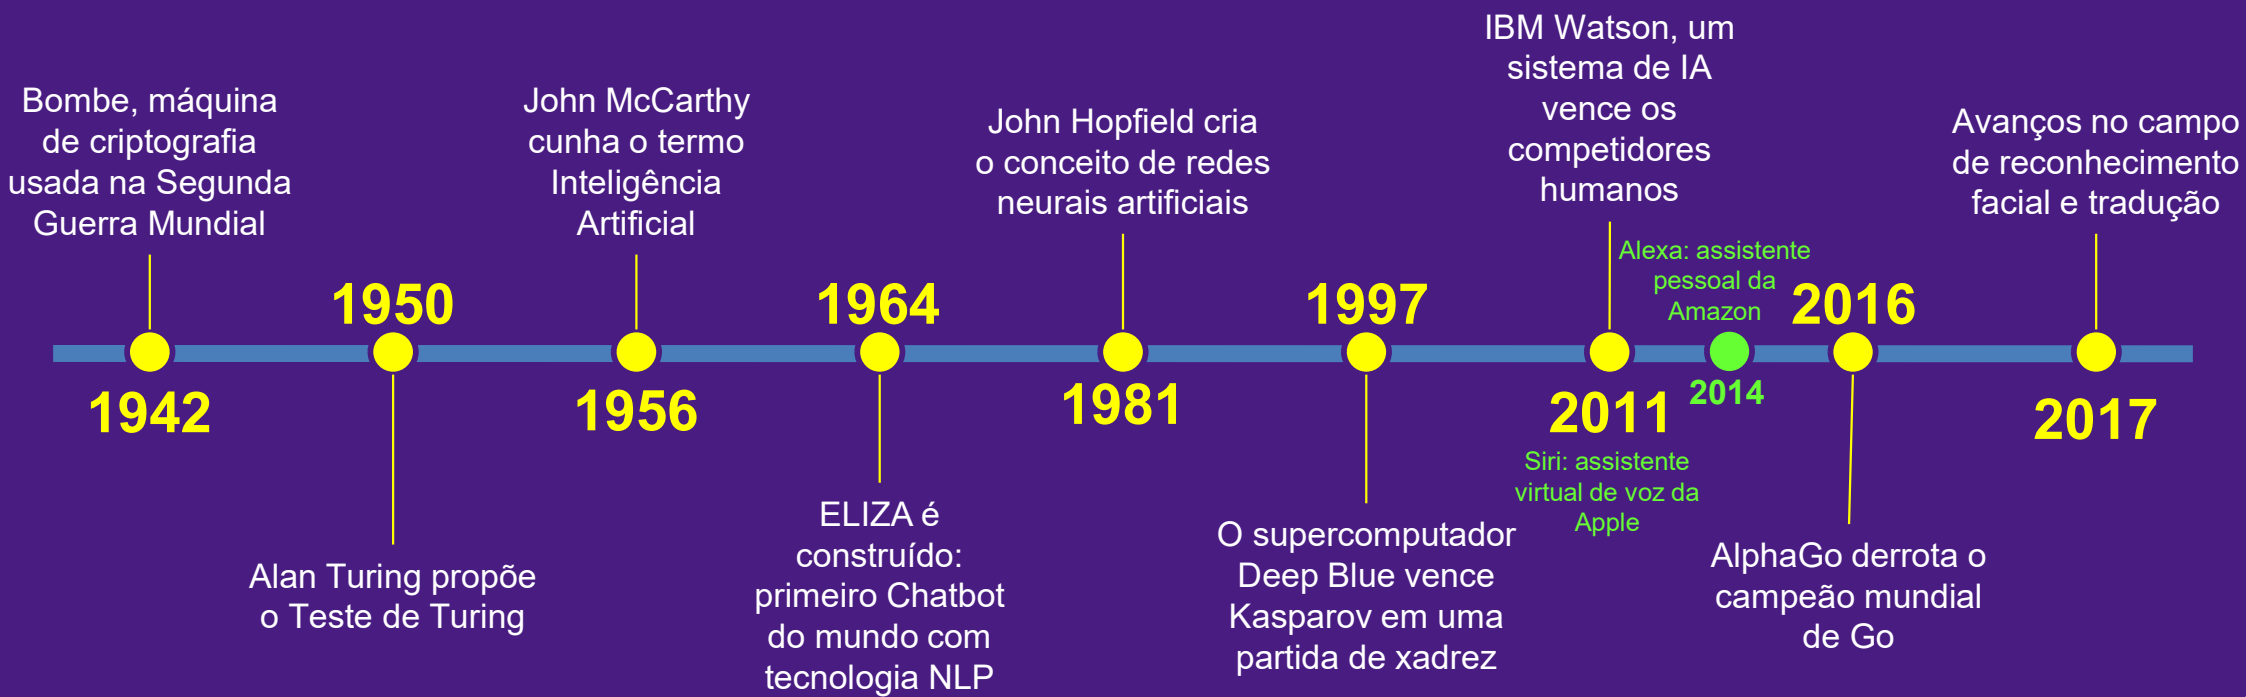
July 15, 2022

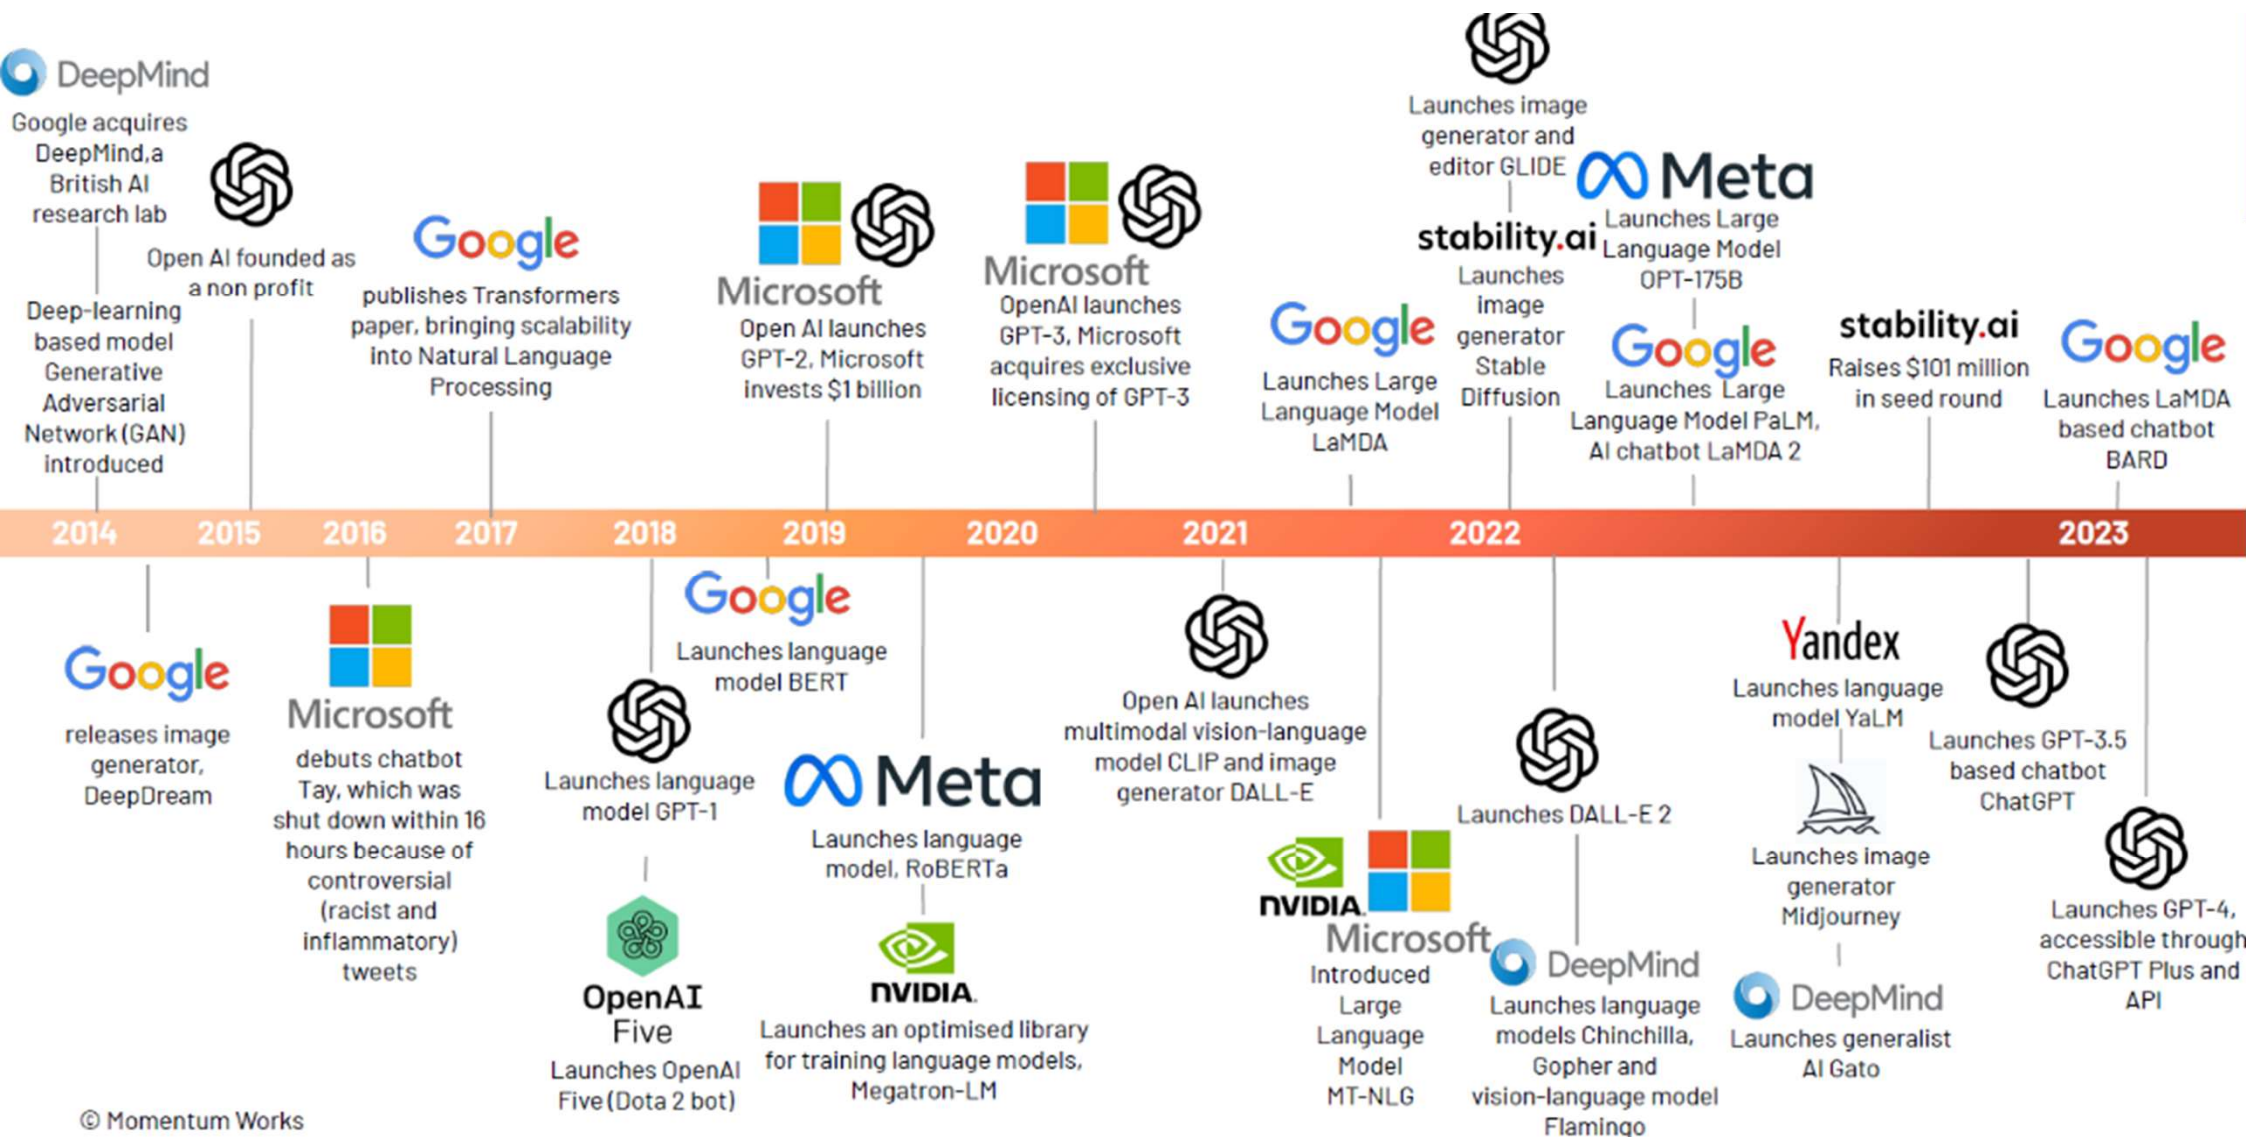


(July 2022)





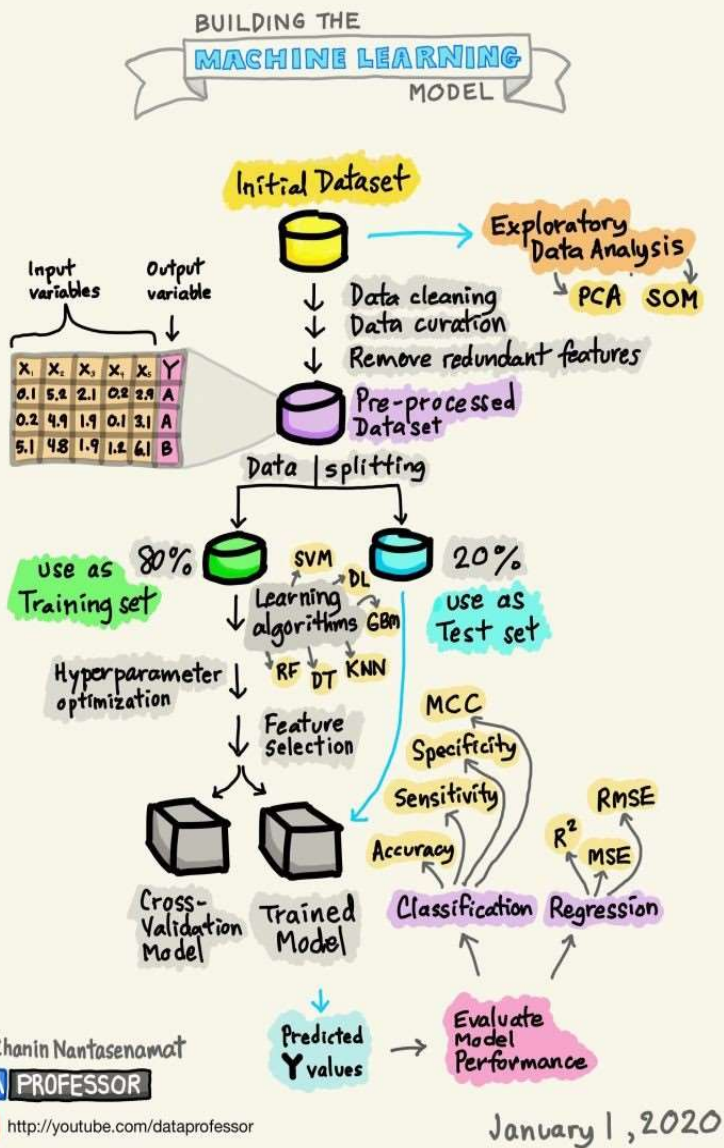
<https://hbr.org/2022/07/is-data-scientist-still-the-sexiest-job-of-the-21st-century>





Fonte: <https://neigrando.com/2023/05/03/ia-generativa-um-relatorio-de-pesquisa-abril-2023/>  
 Fonte: <https://medium.com/@ai.insights/uma-breve-hist%C3%B3ria-da-evolu%C3%A7%C3%A3o-da-intelig%C3%Aancia-artificial-cb2b10f24e2c>





# A Beginner's Guide to The Machine Learning Workflow

